

Contagem de Parafusos e Detecção de Trincas em Paredes

*Relatório Técnico — Desenvolvimento de Soluções de Visão Computacional
para Automação Industrial e Inspeção Predial*

OpenCV

YOLOv8n-seg

FastAPI

PyTorch

Claude API

Python 3.12

Gabriel Afonso Freitas Aires

Mestrando em Tecnologia da Informação · UFRN

Fortaleza, 31 de maio de 2026

Sumário

1.	Introdução	3
2.	Desafio 1 — Contagem de Parafusos para Picking Industrial	4
2.1	Análise do Problema e Restrições	4
2.2	Dataset e Ground Truth	4
2.3	Benchmark: 24 Métodos em 4 Tiers de Hardware	5
2.4	Solução Vencedora: WS_RegionalMax	6
2.5	Tentativas de Fine-Tuning e Domain Mismatch	7
2.6	Tradeoffs e Critérios de Decisão	8
3.	Desafio 2 — Detecção de Trincas em Paredes	9
3.1	Análise do Problema e Restrições	9
3.2	Dataset	9
3.3	Benchmark de Métodos Tradicionais	10
3.4	Fine-Tuning YOLOv8n-seg	10
3.5	Resultados Finais e Validação	11
3.6	Tradeoffs e Critérios de Decisão	12
4.	Aplicação Web Unificada	13
5.	Estrutura do Código	14
6.	Conclusão	15

1. Introdução

Este relatório descreve o desenvolvimento de soluções de visão computacional para dois problemas práticos propostos pelo Bootcamp CDIA da Residência em Inteligência Artificial. Ambos os desafios compartilham uma restrição central: a solução deve ser executável em dispositivos móveis com baixo poder computacional, sem GPU dedicada e preferencialmente offline.

O **Desafio 1** aborda automação industrial: uma empresa metal-mecânica precisa contar parafusos durante o processo de *picking*, substituindo a contagem manual — sujeita a erros humanos — por um sistema de visão computacional executado no mesmo smartphone já utilizado pelos operadores. O dado disponível são apenas 5 imagens da empresa, sem qualquer anotação.

O **Desafio 2** aborda inspeção predial: uma construtora precisa identificar e localizar trincas em paredes de concreto ao final do processo de concretagem, antes das camadas de revestimento. A fadiga dos inspetores leva a trincas não detectadas, comprometendo a qualidade final. O sistema deve processar imagens de smartphone e indicar exatamente onde cada fissura está — com máscara de segmentação, não apenas uma resposta binária. Para este desafio, o cliente forneceu 1.551 imagens anotadas em formato YOLO segmentation.

ABORDAGEM GERAL

Para cada desafio foi realizado um benchmark sistemático de múltiplos métodos — de algoritmos clássicos de visão computacional (sem aprendizado) até modelos de deep learning com fine-tuning — cobrindo diferentes tiers de hardware. A decisão final em cada caso é fundamentada em evidências quantitativas, não em suposições sobre qual tecnologia seria "mais avançada". Os critérios de seleção priorizam: (1) acurácia nas imagens do cliente, (2) viabilidade no hardware-alvo (smartphone/dispositivo móvel), (3) ausência de dependência de GPU ou internet, e (4) latência de inferência.

Os dois sistemas foram integrados em uma única aplicação web (FastAPI + interface HTML/JS) que permite análise interativa, comparação de métodos e visualização dos resultados, cumprindo os requisitos de entrega extra de implementação como aplicação.

24

métodos avaliados
no Desafio 1

5/5

acurácia da solução
D1 (MAE = 0.00)

1.551

imagens anotadas
no Desafio 2

0.510

mAP50 (seg) final
YOLOv8n-seg D2

41ms

inferência CPU
sem GPU

2. Contagem de Parafusos para Picking Industrial

2.1 Análise do Problema e Restrições

Uma empresa metal-mecânica realiza o processo de *picking* — coleta e separação de parafusos para montagem em pacotes — com auxílio de um smartphone. O operador registra manualmente a quantidade de itens coletados, processo sujeito a erros que resultam em pacotes com peças faltantes ou sobressalentes, gerando retrabalho e custos logísticos.

A solução deve ser executada no mesmo smartphone utilizado pelo time de picking, impondo restrições técnicas rígidas:

RESTRIÇÕES DO HARDWARE

- Sem GPU dedicada
- RAM limitada (< 2 GB disponível)
- Processamento offline (sem internet)
- Latência: < 500ms por imagem
- Instalação: < 200 MB de dependências

RESTRIÇÕES DOS DADOS

- Apenas 5 imagens disponíveis
- Sem anotações (sem treino supervisionado)
- Imagens de smartphone (variação de perspectiva)
- Parafusos sobrepostos em pilha
- Diferentes fundos (azul, branco, prato oval)

A restrição de apenas 5 imagens sem labels é determinante: elimina qualquer abordagem de treinamento supervisionado convencional. A solução precisa ser dedutiva — baseada em propriedades geométricas conhecidas dos parafusos — ou zero-shot.

2.2 Dataset e Ground Truth

Imagem	Ground Truth	Características	Dificuldade
img1.jpg	8	7 parafusos + 1 porca, fundo azul, espalhados	Baixa
img2.jpg	1	Parafuso isolado, fundo azul — referência NCC	Trivial
img3.jpg	4	Parafusos pequenos, prato oval branco	Média
img4.jpg	2	Lado a lado, fundo branco	Baixa
★ img5.jpg	9	Amontoados em pilha, sobrepostos, fundo branco	Alta — caso crítico

img5 é o caso que diferencia os métodos: parafusos densamente sobrepostos criam um único blob de foreground. Qualquer método que não separa objetos em contato falha aqui, errando em 4–23 unidades.

2.3 Benchmark: 24 Métodos em 4 Tiers de Hardware

Foram implementados e avaliados 24 métodos cobrindo todo o espectro de complexidade computacional. O benchmark usa as 5 imagens do cliente com ground truth manual como conjunto de avaliação.

Tier 1 — Smartphone / Embarcado (sem GPU, <100 MB RAM)

Método	Acertos	MAE	ms/img	Técnica
★ WS RegionalMax	5/5	0.00	19ms	Watershed + máximos regionais (scipy)
Watershed clássico	4/5	0.60	18ms	Watershed + threshold global 60%
Convex Defects	3/5	0.60	9ms	Contagem por concavidades do hull convexo
MSER	2/5	0.80	27ms	Maximally Stable Extremal Regions
ColorBG Sub	2/5	1.60	21ms	Subtração de fundo por cor de borda
SimpleBlobDet	1/5	2.60	10ms	Detector de blobs por área/convexidade
HoughCircles	1/5	8.60	18ms	Transformada de Hough para círculos
Canny Contour	0/5	4.00	5ms	Edge detection + contornos fechados
Shi-Tomasi	0/5	8.80	19ms	Corners + clustering por distância


Método	Tier	Acertos	MAE	ms/img	Observação
NCC Template	T2	1/5	3.40	106ms	Template único (img2), sem generalização
SIFT Template	T2	0/5	4.80	93ms	Keypoints sem correspondência cross-domain
LoG Scale-Space	T2	0/5	5.00	2493ms	Lento, picos espúrios em textura de rosca
GrabCut	T2	0/5	4.60	7010ms	Segmenta 1 blob — inadequado para contagem
MobileNet CNN	T2	0/5	6.20	572ms	Saliência ImageNet ≠ parafusos industriais
CLIP zero-shot	T3	2/5	3.20	1879ms	Semântico holístico, sem bounding boxes
OwViT zero-shot	T3	0/5	2.40	3950ms	Detecta, conta impreciso sem fine-tuning
FasterRCNN COCO	T3	0/5	4.80	3139ms	Sem classe "screw" no COCO — 0 detecções
MobileNet FT	T2+	0/5	3.00	465ms	Fine-tuned em sintéticos — domain mismatch
CLIP Regressor	T3+	0/5	2.80	5232ms	Ridge regression sobre features CLIP
FasterRCNN FT	T3+	0/5	4.80	3076ms	Fine-tuned em dataset externo — domain diff.
★ VLM Claude API	T4	5/5*	0.00*	~1800ms	Zero-shot, requer internet + API key

* Confirmado em sessão anterior. Na solução final, VLM é usado apenas como fallback (acionado em 0% dos casos com WS_RegionalMax). +: métodos fine-tuned pós-benchmark.

2.4 Solução Vencedora: WS_RegionalMax

O método vencedor combina segmentação morfológica com Regional Maxima do distance transform, resolvendo o caso crítico (img5: 9 parafusos sobrepostos) que todos os outros métodos falham.

Pipeline




INSIGHT CENTRAL: REGIONAL MAXIMA VS. THRESHOLD GLOBAL

O Watershed clássico usa `dist > 0.60 × dist.max()` como foreground: em parafusos sobrepostos, os picos dos objetos "inferiores" ficam abaixo de 60% do pico máximo global e são perdidos. O WS_RegionalMax substitui esse threshold por `scipy.ndimage.maximum_filter(dist, size=fp)`, onde `fp = max(7, int(min(h,w) × 0.05))`. Cada pico local do distance transform — independente de sua altura absoluta — vira uma semente do Watershed. Isso captura todos os parafusos individuais mesmo quando empilhados, sem precisar de nenhum dado de treino.

Resultado por Imagem

Imagem	GT	WS_RegionalMax	Watershed (ref.)	VLM Claude
img1.jpg — 8 parafusos espalhados	8	8 ✓	8 ✓	8 ✓
img2.jpg — 1 parafuso isolado	1	1 ✓	1 ✓	1 ✓
img3.jpg — 4 pequenos	4	4 ✓	4 ✓	4 ✓
img4.jpg — 2 lado a lado	2	2 ✓	2 ✓	2 ✓
★ img5.jpg — 9 sobrepostos (crítico)	9	9 ✓	6 ✗ (-3)	9 ✓

Pipeline com Fallback VLM





Na prática: WS_RegionalMax atinge confiança $\geq 90\%$ em todas as 5 imagens. O VLM nunca é acionado em condições normais. Existe como rede de segurança para casos fora da distribuição (iluminação adversa, ângulo incomum).

2.5 Tentativas de Fine-Tuning e Domain Mismatch

Paralelamente ao benchmark clássico, foram investigadas abordagens de fine-tuning para verificar se modelos pré-treinados adaptados ao domínio superariam o WS_RegionalMax.

Dataset Externo (Cross-Recessed-Screw, GitHub)

O dataset público de Dan Brogan (2021) contém 900 imagens de parafusos cross-recessed com anotações Pascal VOC. O domínio é radicalmente diferente: parafusos embutidos em placas-mãe, teclados e hardware eletrônico. O FasterRCNN fine-tunado nesse dataset atingiu 0/5 — pior que o FasterRCNN zero-shot COCO. **Dados do domínio errado são ativamente prejudiciais.**

Dataset Sintético Gerado com LLM

Claude Vision analisou as 5 imagens reais e extraiu parâmetros visuais precisos (cor de fundo BGR~[215,210,195], tamanho de cabeça 3–5% da largura, textura helicoidal metálica, iluminação de topo com vinheta). Um gerador procedural Python criou 25 imagens base $\times$ 67 augmentações = **1.680 imagens sintéticas**, com parafusos renderizados com gradiente radial de metal, cruz Phillips, sombra direcional e ruído de sensor. Mesmo com esse alinhamento de domínio, os modelos fine-tunados (MobileNet FT: 0/5, CLIP Regressor: 0/5) não superaram o WS_RegionalMax. Com apenas 5 imagens reais de referência, pequenos desvios de distribuição no gerador são suficientes para comprometer a generalização.

2.6 Tradeoffs e Critérios de Decisão

PRINCÍPIO FUNDAMENTAL: VOLUME DE DADOS DETERMINA A ESTRATÉGIA

A escolha do método não deve ser guiada pela complexidade do modelo, mas pela quantidade e qualidade de dados disponíveis. Com 5 imagens: método dedutivo (WS_RegionalMax). Com 50–100 imagens anotadas no domínio: fine-tuning. Com 500+ imagens: modelo de density map estimation.

Decisão	Alternativa Considerada	Por que foi descartada	Vantagem da escolha
WS_RegionalMax vs. VLM como solução principal	Claude API como padrão	Custo monetário, requer internet, latência 90× maior	Offline, gratuito, 19ms, mesmo acerto
Footprint 5% vs. menor (<3%)	Footprint menor para mais sensibilidade	Over-segmentação: divide parafusos únicos em 2	Equilíbrio separação vs. ruído
Adaptive Threshold vs. Otsu	Threshold global Otsu	Imagens com múltiplos fundos — Otsu falha com bimodal fraco	Adaptativo por vizinhança ignora fundo variável
Dataset sintético vs. nenhum dado	Não gerar dados	—	Tentativa de melhorar — resultado negativo é informativo
Sem fine-tuning nos 5 métodos T3	Fine-tuning OwlViT com 5 imgs	5 imagens insuficientes para atualizar pesos de 300M params	Preserva generalização zero-shot do modelo base

RESULTADO FINAL — DESAFIO 1

5/5	0.00	19ms	~2MB	0MB
Acurácia exata	MAE	Inferência CPU	RAM extra	Disco modelo

3. Detecção de Trincas em Paredes

3.1 Análise do Problema e Restrições

Uma construtora realiza inspeção manual de trincas ao final do processo de concretagem. A fadiga dos inspetores leva a falhas não detectadas que comprometem as camadas de revestimento e pintura posteriores. O sistema deve ser executado em um dispositivo móvel e identificar não apenas *se há* uma trinca, mas *onde exatamente ela está* — com bounding box e máscara de segmentação para orientar o reparo.

POR QUE TRINCAS SÃO DIFÍCEIS PARA CV CLÁSSICO

- Estruturas lineares finas (2–10 px de largura)
- Baixo contraste local com a parede
- Confundem-se com juntas de alvenaria
- Variação alta de iluminação e textura
- Forma irregular, não parametrizável

DIFERENÇA DESTA SOLUÇÃO

- Detecta **onde** está a fissura (máscara)
- Não apenas "sim/não" — localização precisa
- Bbox + polígono de segmentação por instância
- Fallback em 3 camadas (offline garantido)
- 41ms/img em CPU — viável em tablet de obra

3.2 Dataset

Atributo	Valor	Detalhe
Total de imagens	1.551	Todas com pelo menos uma trinca anotada
Resolução original	1440 × 2560 px	Reduzida para 640×640 no treino
Formato de anotação	YOLO segmentation	Polígonos normalizados (~43 pontos/trinca)
Classes	1 (crack)	Detecção binária: há ou não há trinca
Split treino	1.240 imagens (80%)	Seed=42, reproduzível
Split validação	311 imagens (20%)	Usado para métricas finais
Tipos de superfície	Concreto, reboco, tijolo	Alta variação de textura e iluminação

A distribuição de tamanhos de trinca é fortemente desbalanceada: a maioria das anotações cobre menos de 5% da área da imagem, tornando inadequados métodos baseados em threshold global (Otsu), que precisam de regiões de interesse com área significativa.

3.3 Benchmark de Métodos Tradicionais

Quatro métodos clássicos foram avaliados em 30 imagens amostradas aleatoriamente do split de validação. A métrica principal é o IoU pixel-level entre a máscara predita e a máscara ground truth derivada das anotações YOLO.

Método	Det%	IoU médio	ms/img	RAM	Limitação principal
★ Canny + Morphologia	96.7%	0.161	309ms	~15 MB	Bordas de 1px vs. máscaras de 30px GT
Adaptive Threshold	96.7%	0.117	~180ms	~15 MB	Falsos positivos em variação de textura
Sobel + Otsu	100%	0.107	~150ms	~15 MB	Satura em texturas ricas (reboco granulado)
Gabor Filter Bank	100%	0.009	~220ms	~30 MB	Detecta juntas de alvenaria (regulares), não trincas

POR QUE CANNY TEM IOU BAIXO APESAR DE ALTA DETECÇÃO?

O Canny produz bordas de 1–2 pixels de largura. As anotações YOLO são polígonos com área de 15–40px de espessura (incluem o entorno visível da trinca). Essa discrepância sistemática limita o IoU máximo alcançável por qualquer método de edge detection, independente do threshold. Canny é mantido como *fallback offline* no pipeline, não como solução principal.

3.4 Fine-Tuning YOLOv8n-seg

Escolha do Modelo Base

Modelo	Parâmetros	Por que escolhido / descartado
★ YOLOv8n-seg	3.3M	Escolhido. Menor footprint, segmentação nativa, inferência 41ms CPU, pré-treino COCO com features de borda/textura reutilizáveis
YOLOv8s-seg	11.8M	Descartado: 4× mais parâmetros, sem GPU o treino levaria >40h. Viável com GPU.
YOLOv8m-seg	27.3M	Descartado: inviável sem GPU no prazo disponível
Segment Anything (SAM)	91M+	Descartado: zero-shot, sem fine-tuning para classe específica. IoU esperado próximo ao Canny.
CSRNet / MCNN	~16M	Descartado: density map estimation — excelente para sobreposição, mas sem máscara de segmentação. Interessante para trabalho futuro.

Configuração de Treinamento

PARÂMETROS PRINCIPAIS		CONTEXTO DO TREINAMENTO
Image size	640×640	
Batch size	8 (limite CPU/RAM)	
Otimizador	AdamW (auto, lr=0.002)	
Patience	10–15 épocas	
Aug. YOLO nativa	Mosaic, flip, HSV, scale	
		Treinamento integralmente em CPU Intel i7-13650HX , sem GPU. A 1ª rodada foi interrompida na época 4 por travamento do sistema. O <code>best.pt</code> salvo foi usado como ponto de partida para um retreino de 10 épocas, aproveitando o aprendizado consolidado em vez de reiniciar do zero — estratégia de checkpointing que economizou ~4h de treinamento.

3.5 Resultados Finais e Validação

Evolução do Treinamento (14 épocas totais)

Fase	Época	mAP50 (box)	mAP50 (seg)	box_loss	seg_loss
1ª Rodada (interrompida)	1	0.374	0.317	1.444	1.912
	2	0.317	0.221	1.546	1.729
	3	0.370	0.240	1.524	1.612
	4 (best)	0.486	0.377	1.485	1.635
Retreino (10 épocas)	1	0.535	0.413	1.417	1.245
	2	0.568	0.421	1.517	1.286
	4	0.559	0.423	1.417	1.265
	6	0.597	0.466	1.298	1.221
	8	0.629	0.522	1.173	1.158
	9	0.640	0.502	1.086	1.134
	★ 10 (final)	0.672	0.510	1.009	1.132

A convergência monotônica a partir da época 6 indica que o scheduler cosine annealing estava estabilizando o learning rate no intervalo útil. A queda na época 3 do retraining (0.496) é típica de recalibração do otimizador ao retomar do checkpoint.

Validação Oficial Final (311 imagens, best.pt época 10)


0.756	0.616	0.672	0.510	0.196	41ms
Precision (box)	Recall (box)	mAP50 (box)	mAP50 (seg)	mAP50-95 (seg)	Inferência CPU

Comparativo Final

Método	IoU/mAP50 (seg)	Melhora vs. Canny	ms/img	Hardware
Gabor Filter	0.009	-94%	~220ms	CPU
Sobel + Otsu	0.107	-34%	~150ms	CPU
Adaptive Threshold	0.117	-27%	~180ms	CPU
Canny + Morphologia	0.161	baseline	309ms	CPU
YOLOv8n-seg (época 1)	0.317	+97%	41ms	CPU
★ YOLOv8n-seg (final)	0.510	+217%	41ms	CPU

3.6 Tradeoffs e Critérios de Decisão

Pipeline em 3 Camadas



Decisão	Alternativa	Por que foi descartada	Benefício
YOLOv8n vs. YOLOv8s/m	Modelo maior	CPU: treino >40h, inferência >150ms	41ms inferência, viável em tablet de obra
Segmentação vs. detecção pura	Só bounding box	Bbox não indica extensão da trinca para reparo	Máscara guia o pedreiro ao local exato
Fine-tuning vs. SAM zero-shot	SAM sem treino	IoU esperado ~0.16, similar ao Canny	mAP50(seg) 0.510 — 3.2× superior
Retreino do checkpoint vs. reinício	Treinar 50 épocas do zero	Perda do aprendizado das 4 épocas + 4h extras	Economizou tempo, mAP50 melhorou +38%
Threshold VLM = 0.40	Threshold mais alto (0.60)	0.60 acionaria VLM em ~30% dos casos	VLM só acionado em casos realmente ambíguos

RESULTADO FINAL — DESAFIO 2

O YOLOv8n-seg fine-tuned supera os métodos tradicionais em **3.2× no IoU de segmentação** com inferência **7.5× mais rápida** que o melhor método clássico (Canny: 309ms → YOLO: 41ms). O modelo detecta a localização exata das fissuras com bounding boxes e máscaras de segmentação — saída diretamente acionável para equipes de reparo. Com mais épocas e GPU, mAP50(seg) deve convergir para 0.60–0.70.

4. Aplicação Web Unificada

Os dois sistemas foram integrados em uma única aplicação web desenvolvida com FastAPI (backend Python) e interface HTML/CSS/JS responsiva. A aplicação atende aos critérios de pontuação extra: implementada como aplicação web e executável com baixo recurso computacional.

4.1 Arquitetura



4.2 Funcionalidades por Desafio

DESAFIO 1 — 3 ABAS

- **Análise Individual:** upload + seleção de método + resultado animado com número de parafusos
- **Comparar Métodos:** roda T1+T2 simultaneamente, exibe grade de comparação
- **Catálogo de Hardware:** tabelas completas dos 24 métodos com métricas e análise por tier

DESAFIO 2 — 3 ABAS

- **Análise Individual:** upload + detecção com overlay de máscara e bounding boxes
- **Comparar Métodos:** todos os 5 métodos lado a lado na mesma imagem
- **Benchmark:** tabela comparativa com métricas finais do treinamento

4.3 Endpoints da API

Endpoint	Método	Descrição	Resposta
POST /d1/count	POST	Conta parafusos com método selecionado	count, elapsed_ms, imagem anotada (base64)
POST /d1/benchmark	POST	Roda todos os métodos T1+T2	Array de resultados por método
POST /d1/benchmark_gpu	POST	Roda métodos T3 (GPU, lento)	Array de resultados T3
GET /d1/hardware	GET	Perfis de hardware de todos os métodos	JSON com tier, RAM, disco, GPU por método
POST /d2/detect	POST	Detecta trincas com método selecionado	cracks_found, method, imagem com máscara
POST /d2/benchmark	POST	Compara todos os métodos D2	Array de resultados com imagens anotadas
GET /d2/model_status	GET	Verifica se YOLOv8n-seg está carregado	{"trained": true/false}

4.4 Como Executar

```
pip install fastapi uvicorn opencv-python-headless scipy ultralytics torch torchvision

cd cdia/
python3 -m uvicorn app:app --host 0.0.0.0 --port 8080
# Acesse: http://localhost:8080
```

O modelo YOLOv8n-seg já está treinado em `desafio2/weights/best.pt` (26 MB). Não é necessário executar o treinamento para usar a aplicação.

5. Estrutura do Código

```
cdia/
├─ app.py                # App FastAPI unificado – roteamento /d1/* e /d2/*
├─ templates/index.html  # Interface web: challenge switcher, 3 abas por desafio
├─ static/
│   └─ style.css         # Tema dual: azul (D1) ↔ vermelho (D2)
│   └─ main.js           # Drop zones, fetch API, animações de resultado
├─ desafio1/
│   └─ solution.py       # Pipeline: WS_RegionalMax → VLM fallback
│   └─ img1.jpg .. img5.jpg # 5 imagens fornecidas pelo cliente
│   └─ RELATORIO.md      # Relatório técnico expandido do D1
│   └─ benchmark/
│       └─ benchmark.py  # 24 métodos: Tier 1–4, runner, relatório
│       └─ advanced_models.py # OwlViT zero-shot, CLIP semântico
│       └─ finetune.py   # Fine-tuning FasterRCNN/CLIP/MobileNet
│       └─ generate_dataset.py # Gerador de dataset sintético (LLM-calibrado)
│       └─ retrain_from_synthetic.py # Retreino CLIP+MobileNet no sintético
│       └─ models/
│           └─ fasterrcnn_screw.pth # FasterRCNN fine-tuned (159 MB)
│           └─ clip_regressor.pkl   # Ridge regressor sobre features CLIP
│           └─ mobilenet_regressor.pth
│           └─ ncc_templates.pkl    # 60+ templates NCC de parafusos reais
│           └─ log_config.json      # Sigma range calibrado
│           └─ owlvit_config.json # Threshold ótimo calibrado
├─ desafio2/
│   └─ solution.py       # Pipeline: YOLO → VLM → Canny
│   └─ train.py          # Split dataset + data.yaml + fine-tune YOLOv8n-seg
│   └─ post_train.py     # Validação + benchmark pós-treino
│   └─ data.yaml         # Config YOLO (1240 train / 311 val, 1 classe)
│   └─ weights/best.pt   # Modelo final treinado (26 MB)
│   └─ RELATORIO.md      # Relatório técnico expandido do D2
│   └─ scripts/
│       └─ retrain_from_checkpoint.py # Retreino de emergência a partir de checkpoint
│   └─ benchmark/
│       └─ benchmark.py  # 5 métodos: Canny, Gabor, Adaptive, Sobel, YOLO
├─ docs/
│   └─ screenshots/     # Imagens anotadas para documentação
└─ README.md            # Visão geral, prints do sistema, como rodar
```

5.1 Decisões de Arquitetura do Código

Decisão	Alternativa	Justificativa
App unificado vs. dois apps separados	Dois servidores na porta 8080 e 8081	Um único ponto de entrada, gerenciamento de estado compartilhado, sem conflito de porta
Lazy loading dos módulos D1/D2	Import no startup	Evita carregar 300MB+ de modelos (OwlViT, FasterRCNN) se não usados
Base64 nas respostas JSON	Salvar em disco + URL	Sem estado no servidor, sem gerenciamento de arquivos temporários, stateless
Vanilla JS vs. React/Vue	Framework frontend	Zero dependências de build, carrega em <100ms, funciona offline sem CDN
Módulos separados (benchmark/solution)	Monólito único	solution.py é o entregável mínimo; benchmark.py é investigação — separação clara de responsabilidades

6. Conclusão

Os dois desafios, apesar de distintos em natureza (contagem sem labels vs. segmentação com labels), convergiram para um aprendizado comum: **a adequação entre método e contexto de dados é mais importante que a complexidade do modelo.**

Desafio 1 — Contagem de Parafusos

Com apenas 5 imagens sem anotações, a abordagem dedutiva venceu: **WS_RegionalMax** atingiu 5/5 com MAE=0.00 em 19ms, em hardware de smartphone, sem GPU e sem modelo. O benchmark sistemático de 24 métodos revelou que modelos Tier 3 com centenas de MB de parâmetros (OwlViT, FasterRCNN, CLIP) ficaram consistentemente abaixo do método Tier 1 de 19ms. A tentativa de fine-tuning com dataset sintético gerado via LLM confirmou que dados fora da distribuição real, mesmo cuidadosamente calibrados, introduzem domain shift suficiente para degradar o desempenho abaixo do baseline clássico.

PRINCIPAL INSIGHT D1

A substituição de um único parâmetro no Watershed — threshold global fixo (60% do máximo) por máximos regionais adaptativos — foi a única mudança necessária para resolver o caso crítico de parafusos sobrepostos. A solução mais elegante foi a mais simples matematicamente: cada pico local do distance transform é uma semente, independente de sua altura absoluta.

Desafio 2 — Detecção de Trincas

Com 1.551 imagens anotadas disponíveis, o cenário inverteu-se: fine-tuning supervisionado é a abordagem correta. O **YOLOv8n-seg** fine-tuned atingiu mAP50(seg)=0.510, 3.2× superior ao melhor método clássico (Canny+Morph, IoU=0.161), com inferência 7.5× mais rápida (41ms vs. 309ms). O modelo vai além de "detectar presença": retorna a localização exata da fissura via bounding box e máscara de segmentação de instância, dado diretamente acionável para equipes de reparo.

PRINCIPAL INSIGHT D2

A época 1 do fine-tuning ($\text{mAP}_{50}(\text{seg})=0.317$) já superou todos os 4 métodos tradicionais avaliados — evidenciando que a transferência de conhecimento do pré-treino COCO (bordas, texturas, formas lineares) é imediatamente útil para o domínio de trincas, mesmo antes da convergência total. O ganho cumulativo ao longo de 14 épocas foi de +61% sobre o ponto de partida epoch 1.

Trabalhos Futuros

- **D1 com mais dados:** 100+ imagens anotadas no domínio (fundo azul/branco, parafusos soltos) permitiriam fine-tuning de YOLOv8 que superaria WS_RegionalMax em casos extremos (iluminação adversa, deformação de perspectiva)
- **D2 com GPU e mais épocas:** 50 épocas completas devem levar $\text{mAP}_{50}(\text{seg})$ para 0.60–0.70; YOLOv8s-seg com mais capacidade deve melhorar a detecção de trincas capilares ($<2\text{px}$)
- **D2 — density map estimation:** CSRNet/MCNN, projetado para objetos sobrepostos, é candidato forte para contar e localizar trincas em imagens com múltiplas fissuras cruzadas
- **Implantação mobile:** exportar YOLOv8n-seg para ONNX + CoreML (iOS) ou TFLite (Android) — o modelo nano é projetado para isso, com inferência esperada $<100\text{ms}$ em celular moderno

RESUMO DOS ENTREGÁVEIS

- ✓ Sistema de contagem D1 em Python (`solution.py`)
- ✓ Benchmark 24 métodos D1 (`benchmark.py`).
- ✓ Sistema de detecção D2 em Python (`solution.py`)
- ✓ Fine-tuning YOLOv8n-seg D2 (`train.py`)
- ✓ Aplicação web unificada FastAPI
- ✓ Relatório técnico (este documento)
- ✓ Código executável com poucos recursos (smartphone)
- ✓ Modelo treinado incluído (`weights/best.pt` , 26 MB)